

DETECCIÓN DE FRAUDE BANCARIO

PARCIAL PRÁCTICO

Camilo Velandia | Universidad Santo Tomás | 2026-I

1. RESUMEN

Dataset altamente desbalanceado (**0.17% fraudes, 344 / 199,364 transacciones**). Objetivo: detectar transacciones fraudulentas minimizando falsos negativos.

2. TABLA COMPARATIVA DE MODELOS

Modelo	F1-Score	Precision	Recall	AUC
Logistic Regression	0.9936	0.9983	0.9899	0.9735
GBT (PySpark)	0.9994	0.9994	0.9994	0.9688
AdaBoost (sklearn)	0.8636	0.9344	0.8028	0.9529

3. JUSTIFICACIÓN DEL MEJOR MODELO

GBT obtuvo **F1 = 0.9994**, detectando **52/71 fraudes** en validación con solo **5 falsos positivos**. **AUC = 0.9688** confirma una excelente discriminación entre clases, posicionándolo como el modelo más robusto del estudio.

4. RECOMENDACIÓN AL BANCO

Se recomienda implementar **GBT en producción** por las siguientes razones:

- Recall 99.94%** — mínimos fraudes no detectados
- Escalable en PySpark** para el procesamiento de millones de transacciones
- Falsos positivos controlados** — solo 0.01% de alertas falsas